CVIČENIE 4:
OPTIMALIZAČNÉ METÓDY HĽADANIA MINIMA

ÚVOD: PREČO SA ZAOBERAŤ OPTIMALIZÁCIOU?

Optimalizácia je proces hľadania *najlepšieho* riešenia – napr. minima alebo maxima nejakej funkcie.
V praxi sa s ňou stretnete v každom modeli strojového učenia, pri trénovaní parametrov siete, hľadaní najlepšej cesty, pri plánovaní výroby atď..

- Zjednodušene → chceme nájsť také x^*, pre ktoré platí $f(x^*) = \min f(x)$
- Rozdeľujeme metódy na:

1D aj 2D

Gradientná metóda

Krok proti smeru derivácie (gradientu). Potrebuje **1. derivácie**.

1D aj 2D

Newtonova metóda

Skok do minima lokálneho kvadratického modelu. Potrebuje **1. aj 2. derivácie**.

2D

Nelder–Mead

Pohyb trojuholníka (simplexu) po ploche. Potrebuje **iba hodnoty *f***.

Optimalizačné metódy v **1D**:
Gradient descent
a **Newtonova metóda**

GRADIENTNÁ METÓDA

$$x_{k+1} = x_k - \alpha f'(x_k)$$

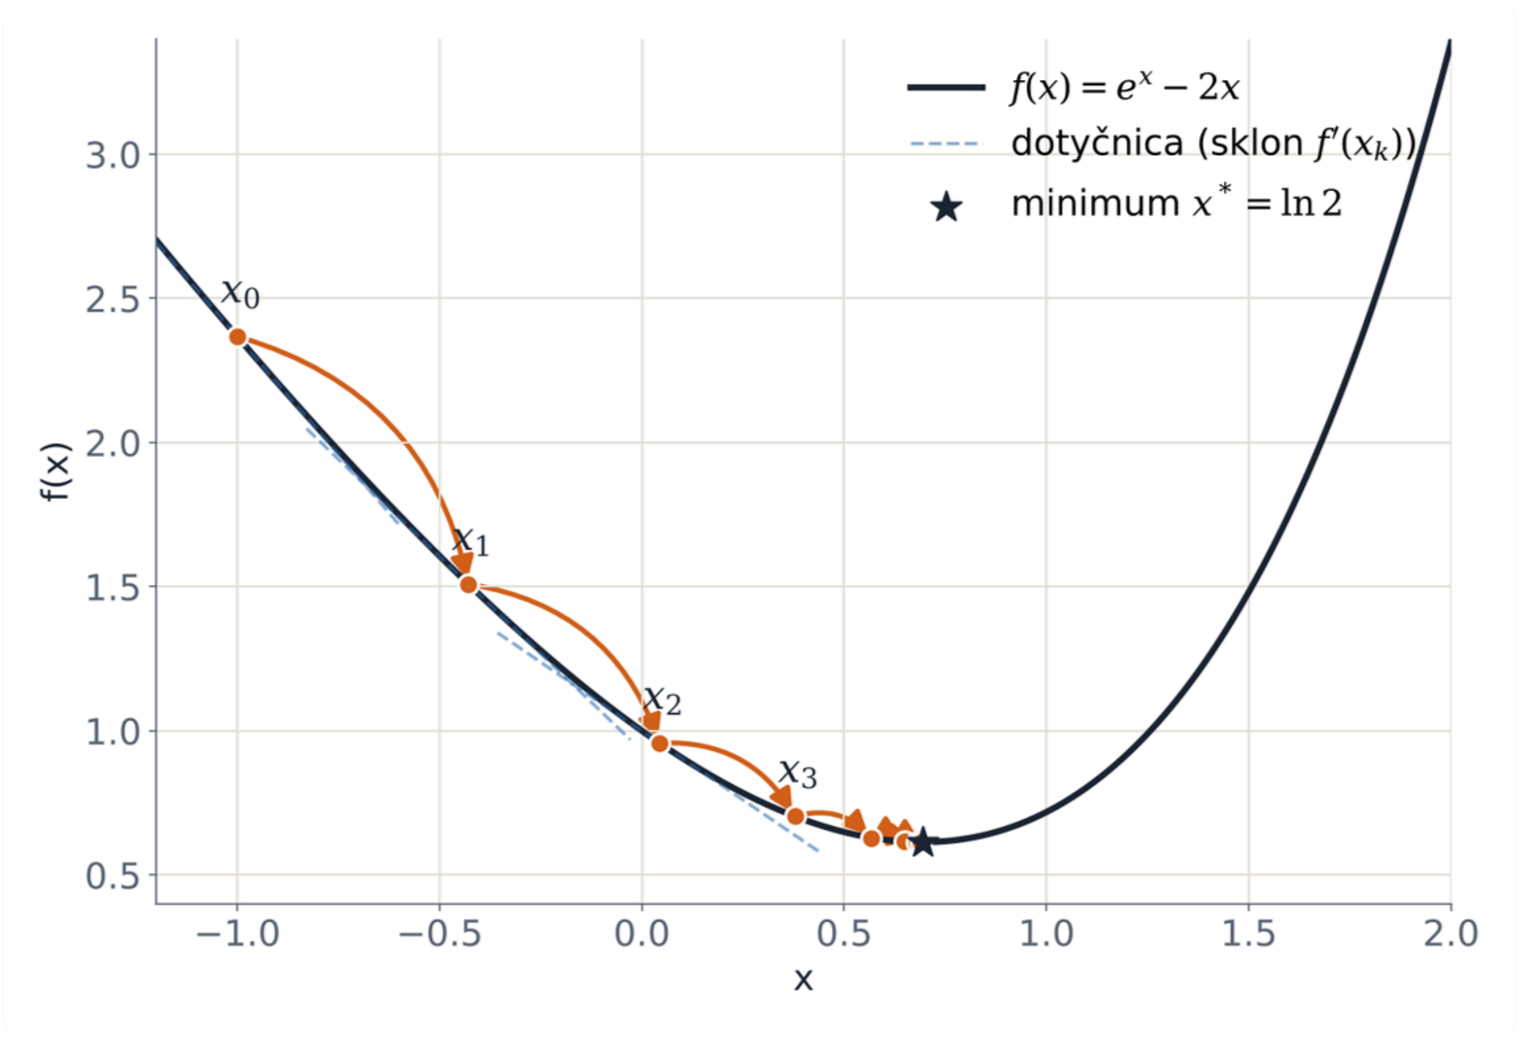
$\boldsymbol{x_k}$ — aktuálny odhad v *k*-tej iterácii

$\boldsymbol{\alpha}$ — dĺžka kroku (krok učenia), napr. 0,01 – 0,5

$\boldsymbol{f'(x_k)}$ — derivácia, teda sklon funkcie v bode x_k

znamienko – — pohyb proti sklonu, smerom nadol

GRADIENTNÁ METÓDA



$f(x) = e^x - 2x$

$x_0 = -1$, $\alpha = 0{,}35$

presnosť 10^{-3} po 9 krokoch



NEWTONOVA METÓDA (NEWTON'S METHOD)

Newtonova metóda je iteratívna technika na hľadanie minima alebo koreňov funkcie, ktorá používa ***derivácie*** na rýchle zlepšovanie odhadu riešenia.

Myšlienka:

- Newtonova metóda je iteratívna metóda na hľadanie minima (alebo aj maxima) diferencovateľnej funkcie.
  - Predpokladajme, že funkcia má *prvú* a *druhú deriváciu*.
- Využíva derivácie funkcie na to, aby *iteratívne priblížila k bodu, kde je funkcia minimálna*.
- Začneme bodom x_0 , spočítame hodnotu funkcie a vykreslíme dotyčnicu v tomto bode. Bod, kde sa dotyčnica pretne s osou x, bude x_1 . Potom opakujeme rovnaký postup pre x_1 , získame x_2 a pokračujeme takto, kým nedosiahneme koreň.

$$x_{i+1} = x_i - \frac{f'(x_i)}{f''(x_i)}$$



NEWTONOVA METÓDA (NEWTON'S METHOD) - ALGORITMUS

Vstup: funkcia $f(x)$, prvá derivácia $f'(x)$ a druhá derivácia $f''(x)$, počiatočný odhad minima x_0, tolerancia (presnosť) ε , maximálny počet iterácií $N_{\max}$

!!! x_0 - metóda nefunguje ak je bod v blízkosti extrému, v blízkosti sedlového, inflexného alebo kritického bodu

Výstup: hľadaný bod minima funkcie $f(x)$ (aproximovaný)

- Zvoľ počiatočný bod x_0
- Pre $i = 0, 1, 2, \ldots N_{\max}$:
  - Vypočítaj prvú aj druhú deriváciu v bode x_i $\quad f'(x_i), f''(x_i)$
  - Aktualizuj bod pomocou Newtonovho vzťahu $\quad x_{i+1} = x_i - \dfrac{f'(x_i)}{f''(x_i)}$
  - Skontroluj kritérium zastavenia (toleranciu): ak $\left|x_{i+1} - x_i\right| < \varepsilon$ ukonči výpočet
- Výsledok: našli sme minimum



NEWTONOVA METÓDA (NEWTON'S METHOD) - VIZUALIZÁCIE

https://www.intmath.com/applications-differentiation/newtons-method-interactive.php

ČO AK MÁM NAJSŤ MAXIMUM A NIE MINIMUM?

V optimalizácii väčšina algoritmov je pôvodne odvodená pre hľadanie **minima funkcie**.

Ak chceme nájsť maximum funkcie $f(x)$, môžeme to robiť tak, že budeme minimalizovať jej negáciu:

$$\max f(x) \Leftrightarrow \min[-f(x)]$$

Optimalizačné metódy v 2D :

Steepest decent gradient, **Nelder-Mead**,

a **Newtonova metóda**

STEEPEST GRADIENT DESCENT — NAJSTRMŠÍ ZOSTUP

Gradient $\nabla f(x,y) = \left(\frac{\partial f}{\partial x}(x,y), \frac{\partial f}{\partial y}(x,y) \right)$ je vektor, ktorý ukazuje smer najstrmšeiho rastu funkcie. Ak teda chceme klesať, vezmeme opačný smer, presnejšie $-\nabla f(x,y)$. V každom kroku teda ideme proti gradientu.

Aktualizačné pravidlo (GD): $x_{k+1} = x_k - \alpha \nabla f_x(x_k, y_x), \quad y_{k+1} = y_k - \alpha \nabla f_y(x_k, y_k)$

kde $\alpha > 0$ je veľkosť kroku (learning rate).

- ak je α príliš malá, postup optimalizácie bude síce spoľahlivý, ale veľmi pomalý.
- ak je naopak α príliš veľká, tak môžeme prekročiť minimum

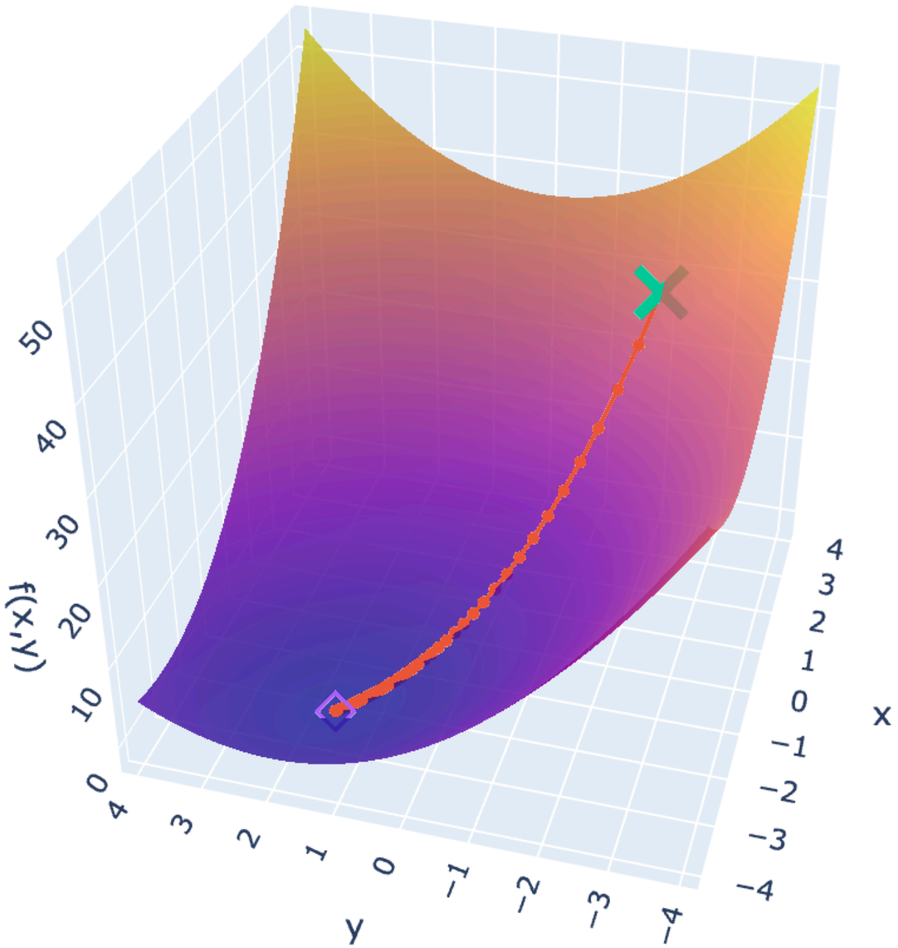
Podmienky fungovania algoritmu:

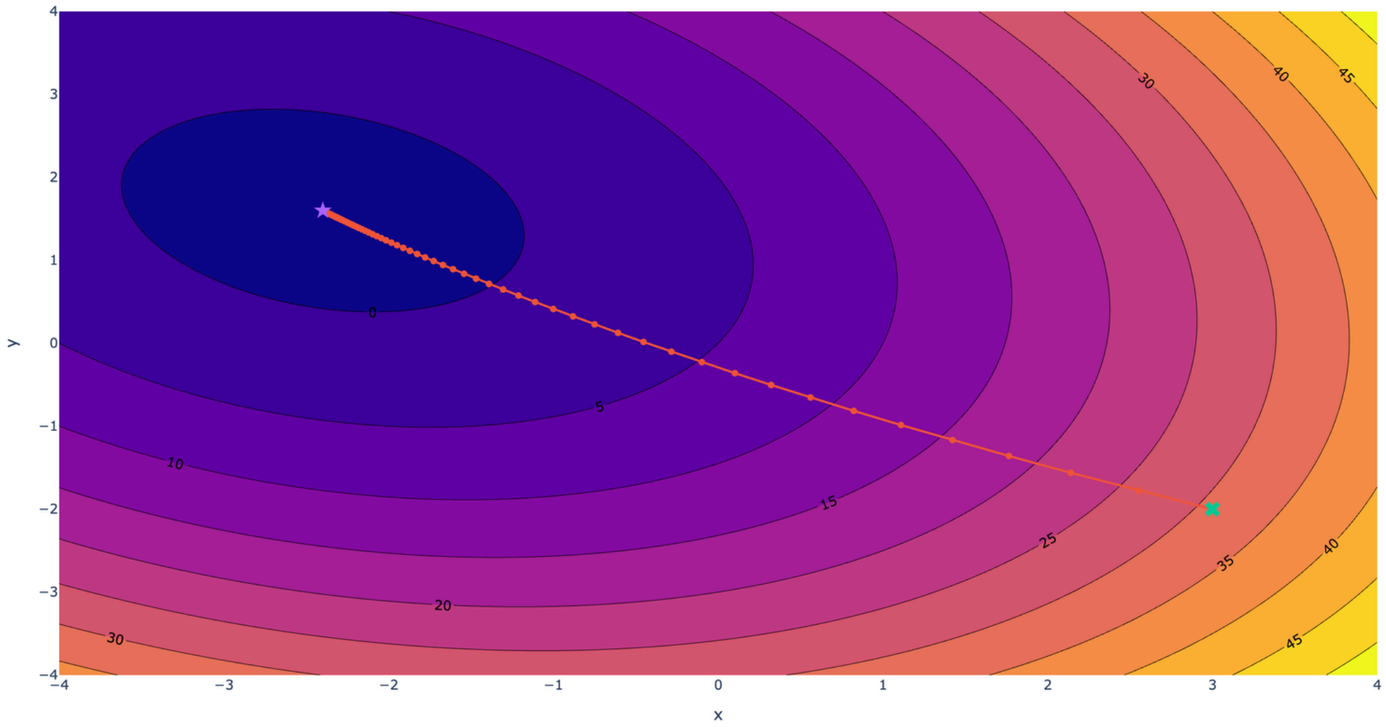
- funkcia f musí byť diferencovateľná

Výhody a nevýhody:

- je jednoduchá a výpočtovo nenáročná ale pomalá (konverguje lineárne)

STEEPEST GRADIENT DESCENT — NAJSTRMŠÍ ZOSTUP

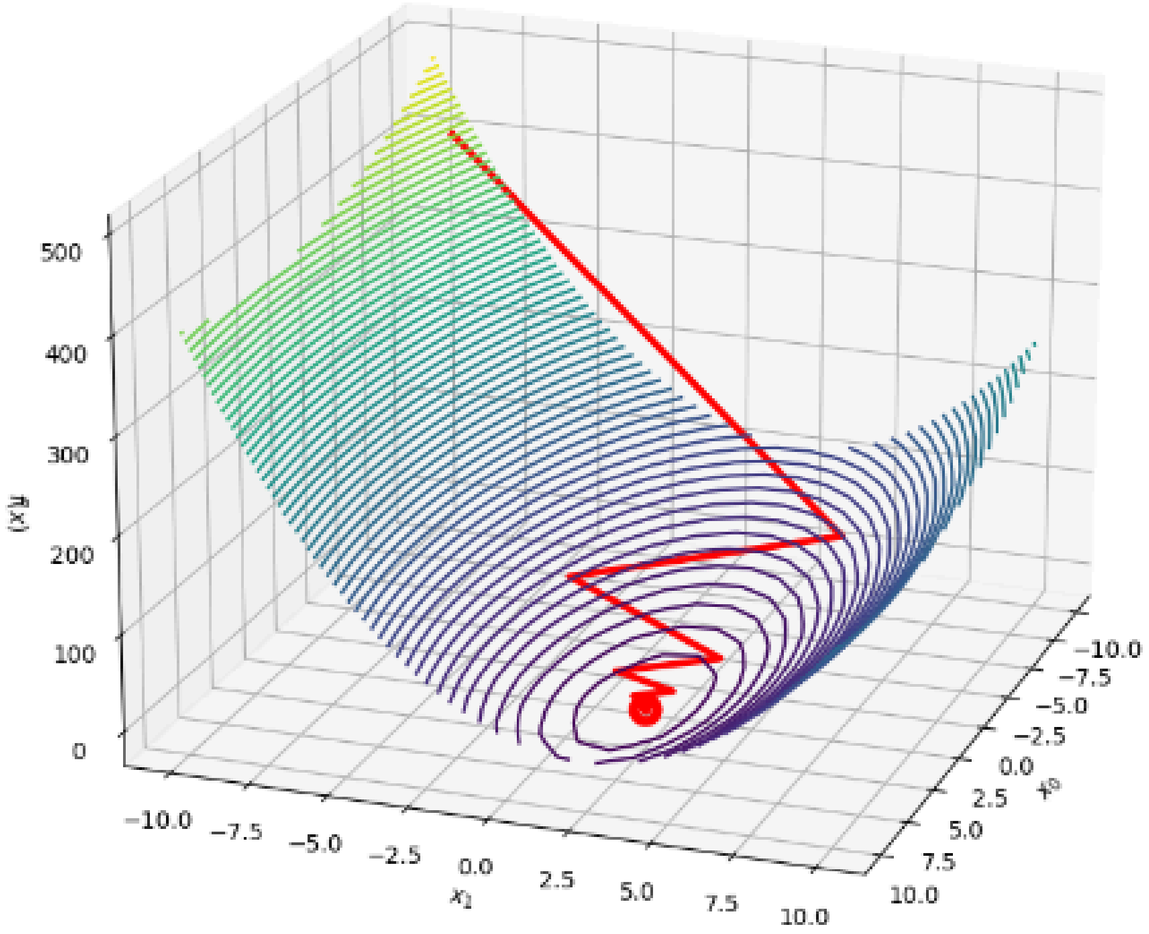


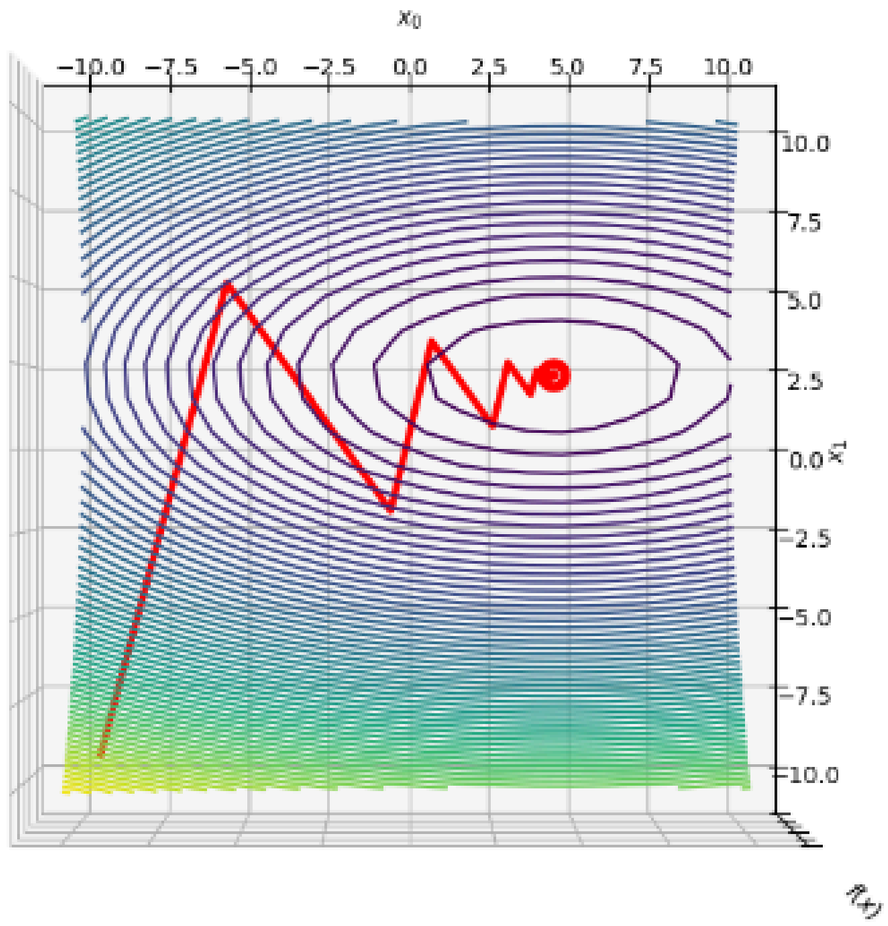


Minimum funkcie f(x,y) = (x+2)^2 + (y−1)^2 + 0.5*x*y je −1.4, v bode (−2.4, 1.6).

Počet iterácií: 266
Odhadnuté minimum v bode: x*=−2.40000000, y*=1.60000000
f(x*, y*) = −1.40000000

STEEPEST GRADIENT DESCENT — NAJSTRMŠÍ ZOSTUP





STEEPEST GRADIENT DESCENT — PRÍKLAD

2D $f(x,y) = x^2 + 2y^2$ $x_0 = [2,2]$

Gradientná metóda (Gradient Descend)

$$x_{k+1} = x_k - \alpha \nabla f(x_k)$$

$\alpha = 0.1$

$f'_x = 2x$

$f'_y = 4y$

1. ITERÁCIA $\nabla f(2,2) = (f'_x, f'_y) = (2 \cdot 2, 4 \cdot 2) = (4,8)$

$x_1 = x_0 - \alpha \cdot \nabla f(x_0) = 2 - 0.1(4) = 1.6$

$y_1 = y_0 - \alpha \cdot \nabla f(y_0) = 2 - 0.1(8) = 1.2$

$[1.6, 1.2]$

2. ITERÁCIA gradient $\nabla f(1.6, 1.2) = (2 \cdot 1.6, 4 \cdot 1.2) = (3.2, 4.8)$

$x_2 = x_1 - \alpha \cdot \nabla f(x_1) = 1.6 - 0.1(3.2) = 1.28$

$y_2 = y_1 - \alpha \nabla f(y_1) = 1.2 - 0.1(4.8) = 0.72$

$[1.28, 0.72]$

NEWTONOVA METÓDA V 2D

Newtonova metóda nevyužíva iba informáciu o smere najväčšieho klesania (gradient), ale aj informáciu o zakrivení optimalizovanej funkcie prostredníctvom Hessovej matice druhých derivácií.

$$H(x,y) = \begin{pmatrix} \frac{\partial^2 f}{\partial x^2}(x,y) & \frac{\partial^2 f}{\partial x \partial y}(x,y) \\ \frac{\partial^2 f}{\partial y \partial x}(x,y) & \frac{\partial^2 f}{\partial y^2}(x,y) \end{pmatrix}$$

Aktualizačné pravidlo je dané:

$$\begin{bmatrix} x_{k+1} \\ y_{k+1} \end{bmatrix} = \begin{bmatrix} x_k \\ y_k \end{bmatrix} - H(x_k, y_k)^{-1} \begin{bmatrix} \frac{\partial f}{\partial x}(x_k, y_k) \\ \frac{\partial f}{\partial y}(x_k, y_k) \end{bmatrix} \begin{cases} x_{k+1} = x_k - H(x_k, y_k)^{-1} \frac{\partial f}{\partial x}(x_k, y_k) \\ y_{k+1} = y_k - H(x_k, y_k)^{-1} \frac{\partial f}{\partial y}(x_k, y_k) \end{cases}$$

Newtonova metóda predpokladá, že funkciu f môžeme v jej okolí nahradiť kvadratickou aproximáciou (**parabolou**).

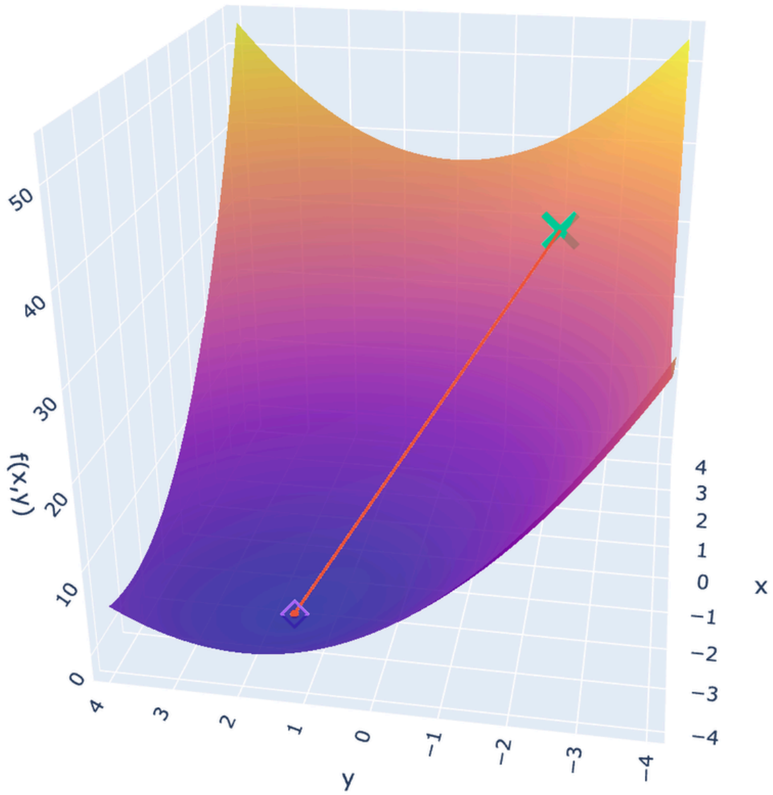
Podmienky fungovania algoritmu:

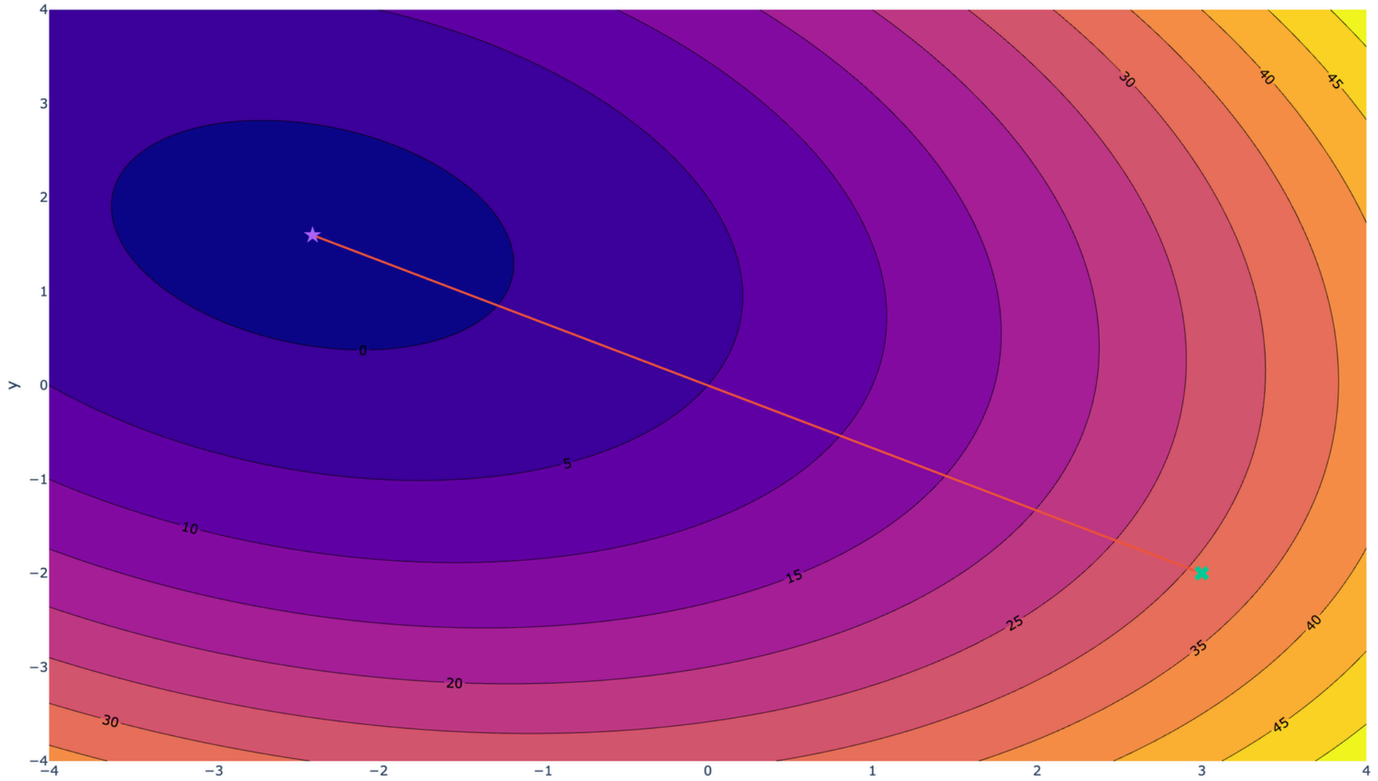
- funkcia musí byť dvakrát **diferencovateľná** (aby sme mohli spočítať Hessovu maticu)

Výhody a nevýhody:

- je rýchla, ale náročná na výpočet

NEWTONOVA METÓDA

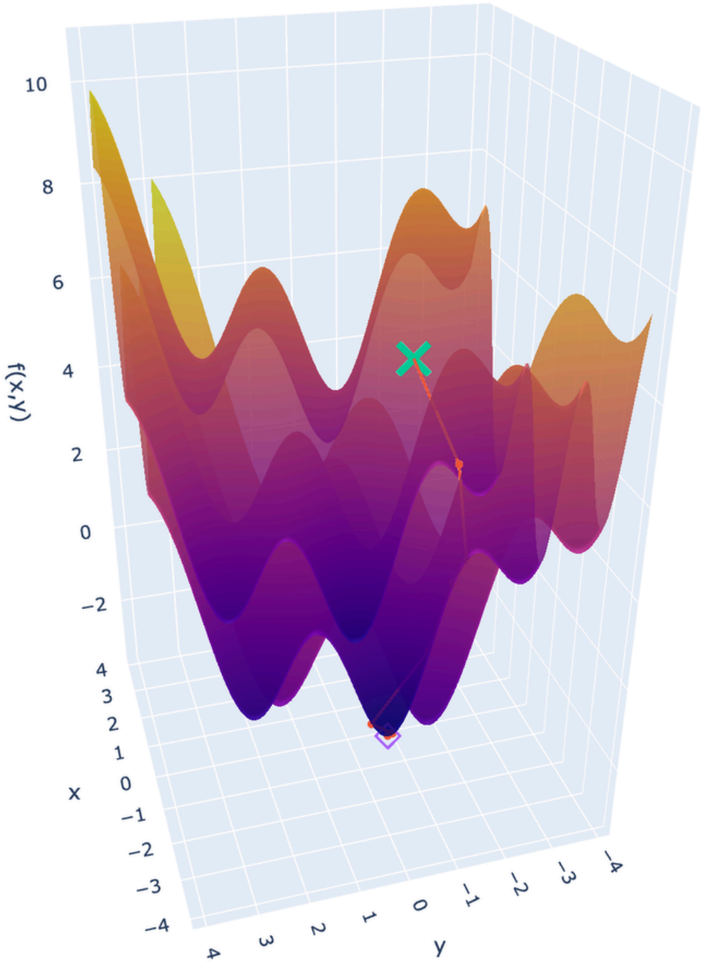


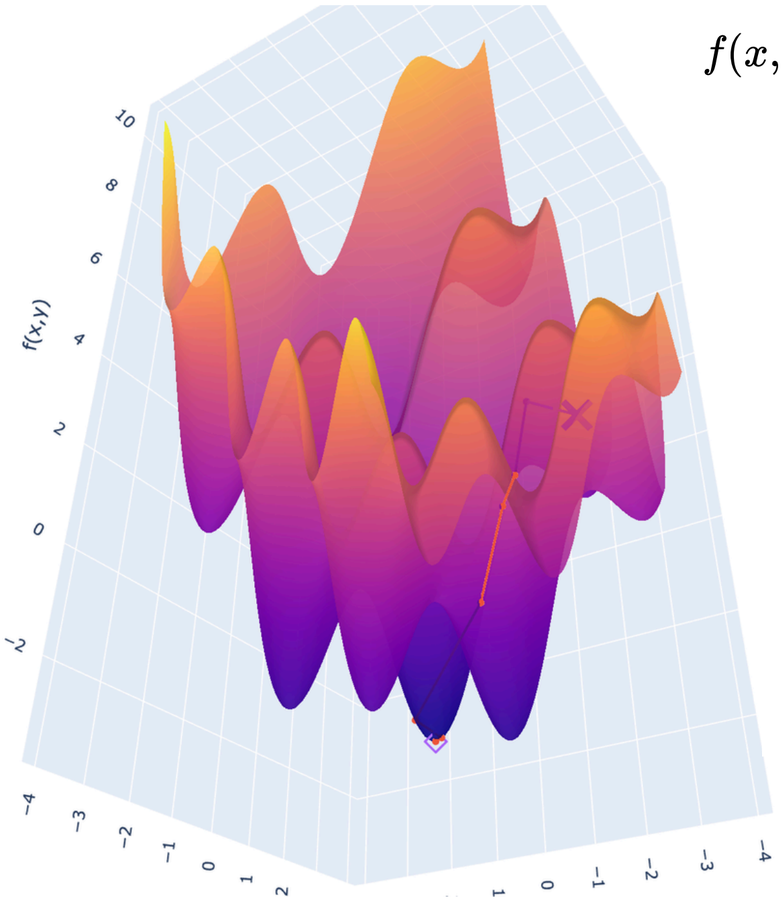


Minimum funkcie f(x,y) = (x+2)^2 + (y−1)^2 + 0.5*x*y je −1.4, v bode (−2.4, 1.6).

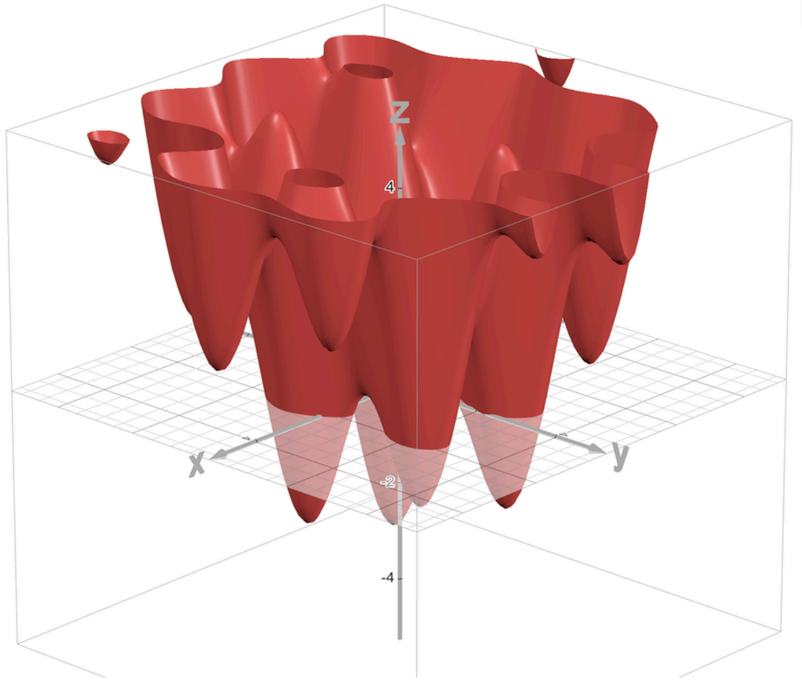
Iterácií: 1
Minimum ≈ (x*, y*) = (−2.40000000, 1.60000000)
f(x*, y*) = −1.40000000

NEWTONOVA METÓDA





$$f(x,y) = 0.25(x^2 + y^2) + 2sin(2.5x) + 1.5sin(2y)$$



NEWTONOVA METÓDA

2D $\quad f(x,y) = x^2 + 2y^2 \quad x_0 = [2,2]$

Newtonova metóda v 2D

$$x_{k+1} = x_k - H^{-1} \nabla f(x_k)$$

H^{-1} = inverzná matica

$$H = \begin{vmatrix} 2 & 0 \\ 0 & 4 \end{vmatrix} \quad H^{-1} = \begin{vmatrix} 0.5 & 0 \\ 0 & 0.25 \end{vmatrix}$$

$\nabla f(x_0) = (4,8)$

1. ITERÁCIA

$x_1 = x_0 - H^{-1} \cdot \nabla f(x_0) = 2 - 0.5 \cdot 4 = 0$

$y_1 = y_0 - H^{-1} \nabla f(y_0) = 2 - 0.25 \cdot 8 = 0$

$[0,0]$

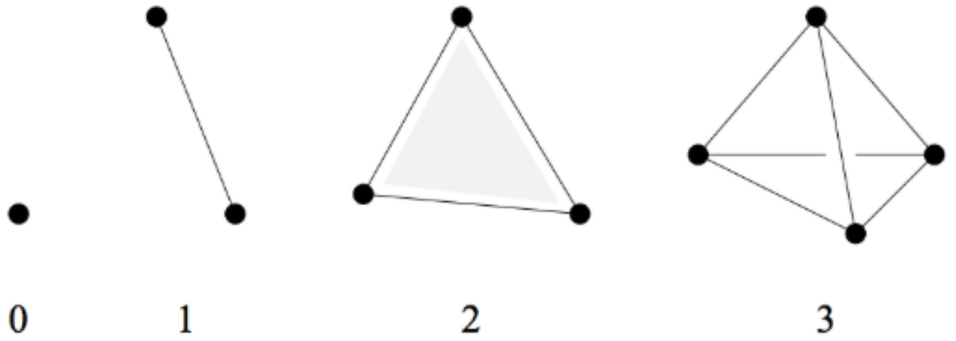
NELDER-MEAD - HĽADANIE LOKÁLNEHO MINIMA

Nelder-Mead metóda je numerická **optimalizačná** technika, ktorá sa používa na hľadanie **lokálneho minima** funkcie.

Ide o **bezderivátovú metódu,** čo znamená, že nevyžaduje výpočet derivácií funkcie.

Využíva iteratívny proces na vylepšovanie odhadu minima pomocou geometrických operácií na tzv. **simplex**, čo je útvar s n **+ 1** vrcholmi v n**-rozmernom priestore**.

Typ metódy: Heuristická, bezderivátová, lokálna optimalizácia
Vstup: Funkcia *f(x)* a počiatočný simplex (súbor bodov)
Výstup: Aproximácia lokálneho minima funkcie *f(x)*
Použitie: Vhodná pre neznáme funkcie, kde výpočet derivácií je náročný alebo nemožný



NELDER-MEAD - ALGORITMUS

Zoraď vrcholy $f(\mathbf{x}_1) \le f(\mathbf{x}_2) \le f(\mathbf{x}_3)$ a nahraď najhorší $\mathbf{x}_3$:

1 · Ťažisko
stred strany oproti $\mathbf{x}_3$

$$\bar{\mathbf{x}} = \tfrac{1}{2}(\mathbf{x}_1 + \mathbf{x}_2)$$

2 · Reflexia
preklop $\mathbf{x}_3$ cez ťažisko

$$\mathbf{x}_r = \bar{\mathbf{x}} + \alpha(\bar{\mathbf{x}} - \mathbf{x}_3)$$

3 · Expanzia
ak $\mathbf{x}_r$ je lepší než $\mathbf{x}_1$ – choď ďalej

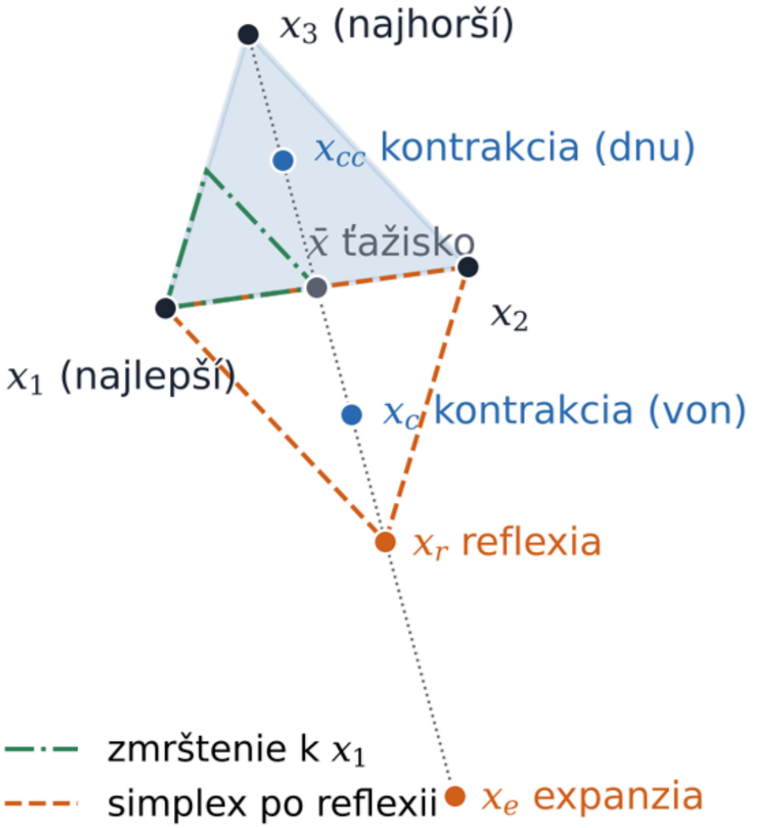
$$\mathbf{x}_e = \bar{\mathbf{x}} + \gamma(\mathbf{x}_r - \bar{\mathbf{x}})$$

4 · Kontrakcia
ak $\mathbf{x}_r$ nie je lepší než $\mathbf{x}_2$

$$\mathbf{x}_c = \bar{\mathbf{x}} + \rho(\mathbf{x}_3 - \bar{\mathbf{x}})$$

5 · Zmrštenie
nič nepomohlo – zmenši k $\mathbf{x}_1$

$$\mathbf{x}_i \leftarrow \mathbf{x}_1 + \sigma(\mathbf{x}_i - \mathbf{x}_1)$$



NELDER-MEAD - ALGORITMUS

Postup:

1. Usporiadaj body podľa hodnoty f: $f(A) \leq f(B) \leq f(C)$.
2. Vypočítaj ťažisko:

best great

$$\mathbf{x}_0 = \frac{A + B}{2}$$

môže sa označovať aj M.

3. **Reflexia:**

$$\mathbf{x}_r = \mathbf{x}_0 + \alpha(\mathbf{x}_0 - C), \quad \alpha = 1 \rightarrow R = M + 1 \cdot (M - W)$$

Ak $f(A) \leq f(x_r) < f(B)$, nahraď $C = x_r$.

4. **Expanzia (ak $f(x_r) < f(A)$):**

$$\mathbf{x}_e = \mathbf{x}_0 + \gamma(\mathbf{x}_r - \mathbf{x}_0), \quad \gamma = 2 \rightarrow E = M + 2 \cdot (R - M)$$

Ak $f(x_e) < f(x_r)$, potom $C = x_e$, inak $C = x_r$.

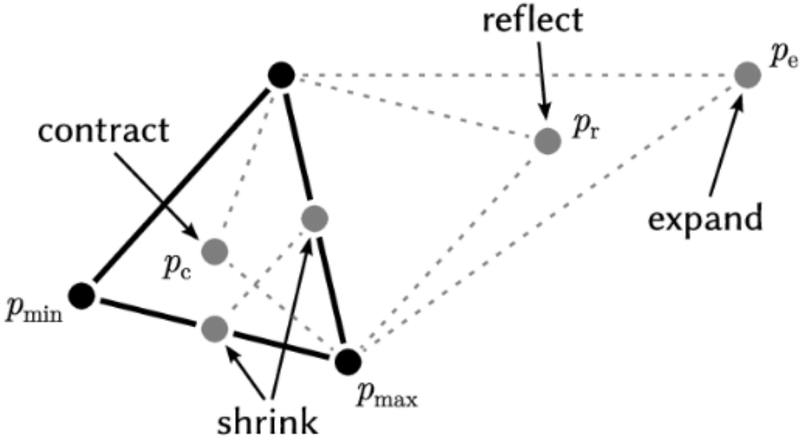
5. **Kontrakcia (ak $f(x_r) \geq f(B)$):**

$$\mathbf{x}_c = \mathbf{x}_0 + \rho(C - \mathbf{x}_0), \quad \rho = 0.5 \rightarrow K = M + \frac{1}{2}(W - M)$$

Ak $f(x_c) < f(C)$, nahraď $C = x_c$, inak všetky body zmenši k A:

$$B = A + \sigma(B - A), \quad C = A + \sigma(C - A), \quad \sigma = 0.5$$

Iterácia 1–2: Urob kroky 1–5, aktualizuj body a opakuj, kým zmeny $f(x)$ sú malé.



NELDER-MEAD - ALGORITMUS VIZUALIZÁCIA

https://alexdowad.github.io/visualizing-nelder-mead/

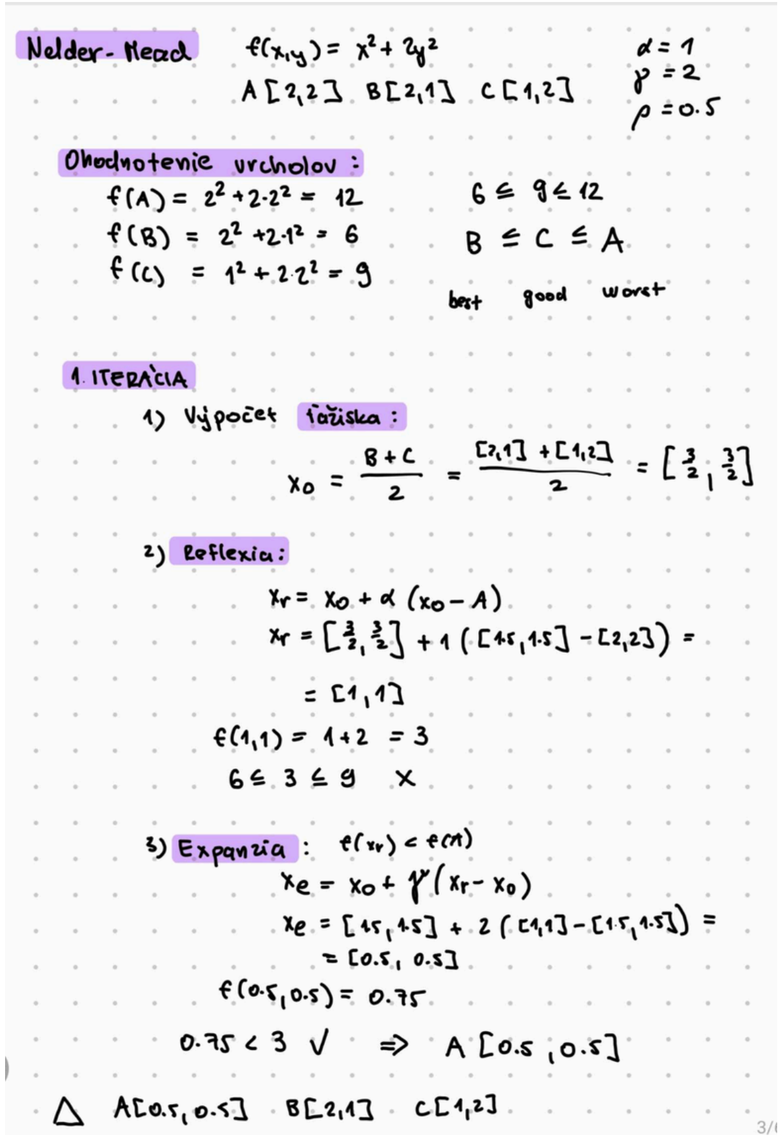
NELDER-MEAD - PRÍKLAD PREDNÁŠKA

Predstavme si jednoduchú dvojrozmernú funkciu: $f(x, y) = x^2 - 4y + y^2 - y - xy$

Počiatočný simplex(trojuholník) obsahuje body: $A(0, 0), B(1.2, 0), C(0, 0.8)$

k	Best point	Good point	Worst point
1	$f(1.2, 0.0) = -3.36$	$f(0.0, 0.8) = -0.16$	$f(0.0, 0.0) = 0.00$
2	$f(1.8, 1.2) = -5.88$	$f(1.2, 0.0) = -3.36$	$f(0.0, 0.8) = -0.16$
3	$f(1.8, 1.2) = -5.88$	$f(3.0, 0.4) = -4.44$	$f(1.2, 0.0) = -3.36$
4	$f(3.6, 1.6) = -6.24$	$f(1.8, 1.2) = -5.88$	$f(3.0, 0.4) = -4.44$
5	$f(3.6, 1.6) = -6.24$	$f(2.4, 2.4) = -6.24$	$f(1.8, 1.2) = -5.88$
6	$f(2.4, 1.6) = -6.72$	$f(3.6, 1.6) = -6.24$	$f(2.4, 2.4) = -6.24$
7	$f(3.0, 1.8) = -6.96$	$f(2.4, 1.6) = -6.72$	$f(2.4, 2.4) = -6.24$
8	$f(3.0, 1.8) = -6.96$	$f(2.55, 2.05) = -6.7725$	$f(2.4, 1.6) = -6.72$
9	$f(3.0, 1.8) = -6.96$	$f(3.15, 2.25) = -6.9525$	$f(2.55, 2.05) = -6.7725$
10	$f(3.0, 1.8) = -6.96$	$f(2.8125, 2.0375) = -6.95640625$	$f(3.15, 2.25) = -6.9525$

NELDER-MEAD - PRÍKLAD



Nelder-Mead $f(x,y) = x^2 + 2y^2$

$A[2,2]$ $B[2,1]$ $C[1,2]$

$\alpha = 1$
$\gamma = 2$
$\rho = 0.5$

Ohodnotenie vrcholov :

$f(A) = 2^2 + 2 \cdot 2^2 = 12$
$f(B) = 2^2 + 2 \cdot 1^2 = 6$
$f(C) = 1^2 + 2 \cdot 2^2 = 9$

$6 \leq 9 \leq 12$
$B \leq C \leq A$
best good worst

1. ITERÁCIA

1) Výpočet ťažiska :

$$x_0 = \frac{B+C}{2} = \frac{[2,1]+[1,2]}{2} = [\tfrac{3}{2}, \tfrac{3}{2}]$$

2) Reflexia :

$x_r = x_0 + \alpha(x_0 - A)$
$x_r = [\tfrac{3}{2}, \tfrac{3}{2}] + 1([1.5, 1.5] - [2,2]) =$
$= [1,1]$
$f(1,1) = 1+2 = 3$
$6 \leq 3 \leq 9$ ×

3) Expanzia : $f(x_r) < f(A)$

$x_e = x_0 + \gamma(x_r - x_0)$
$x_e = [1.5, 1.5] + 2([1,1] - [1.5, 1.5]) =$
$= [0.5, 0.5]$
$f(0.5, 0.5) = 0.75$
$0.75 < 3$ ✓ $\Rightarrow$ $A[0.5, 0.5]$

△ $A[0.5, 0.5]$ $B[2,1]$ $C[1,2]$

3/

2. ITERÁCIA

$f(A) = 0.75$
$f(B) = 6$
$f(C) = 9$

$A \leq B \leq C$

1) Výpočet ťažiska :

$$x_0 = \frac{A+B}{2} = \frac{[0.5, 0.5]+[2,1]}{2}$$

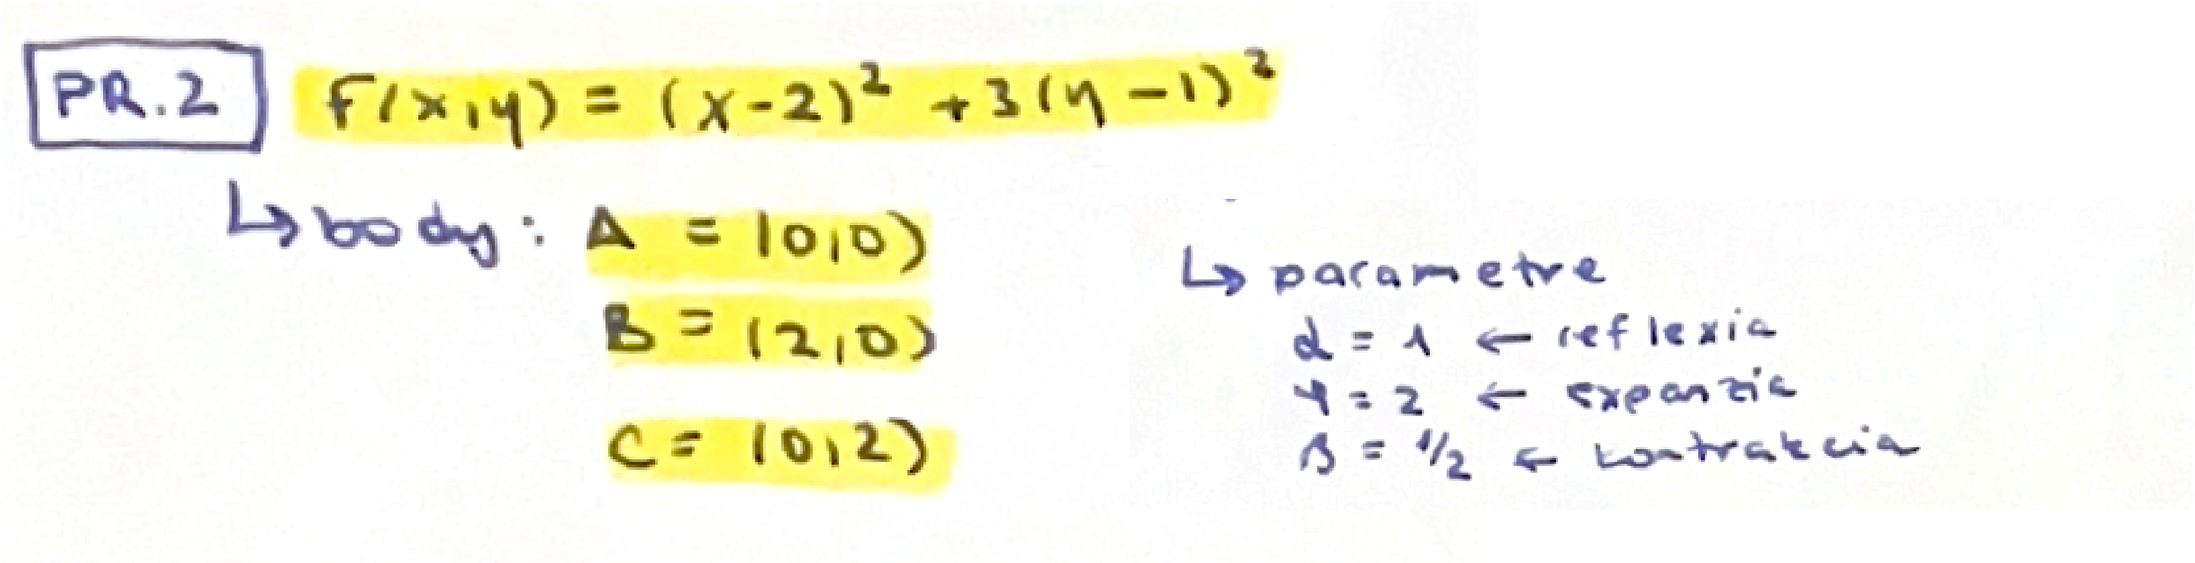
$x_0 = [1.25, 0.75]$

2) Reflexia :

$x_r = x_0 + \alpha(x_0 - C)$
$x_r = [1.25, 0.75] + 1([1.25, 0.75] - [1,2])$
$x_r = [1.5, -0.5]$
$f(x_r) = 2.75$
$0.75 \leq 2.75 \leq 6$ ✓
$C \Rightarrow [1.5, -0.5]$

△ $A[0.5, 0.5]$ $B[2,1]$ $C[1.5, -0.5]$

NELDER-MEAD - PRÍKLAD



NELDER-MEAD - PRÍKLAD

1. ITERÁCIA

Ohodnotenie vrcholov:

$f(A) = (0-2)^2 + 3(0-1)^2 = 7$

$f(B) = (2-2)^2 + 3(0-1)^2 = 3$ $\quad f(B) \leq f(A) \leq f(C)$

$f(C) = (0-2)^2 + 3(2-1)^2 = 7$

1) Centroid: $x_0 = \frac{B+A}{2} = \frac{[2,0]+[0,0]}{2} = [1,0]$

2) Reflexia: $x_r = x_0 + \alpha(x_0 - C)$

$x_r = [1,0] + 1([1,0] - [0,2])$

$x_r = [2,-2]$

$f(x_r) = (2-2)^2 + 3(-2-1)^2 = 27$

$3 \leq 27 \leq 7$ ✗ zhoršila vyjuledole

3) Expanzia ✗ neplatí $f(x_r) < f(B)$

4) Kontrakcia: $f(x_r) > f(B)$

$x_c = x_0 + \beta(C - x_0)$

$y_c = [1,0] + 0.5([0,2] - [1,0]) = [0.5,1]$

$f(x_c) = 2.25$

$f(x_c) < f(C)$

$2.25 < 7$ ✓

$C \Rightarrow x_C$

$A[0,0]$ $B[2,0]$ $C[0.5,1]$

2. ITERÁCIA

$f(A) = 7$

$f(B) = 3$ $\quad f(C) \leq f(B) \leq f(A)$

$f(C) = 2.25$

1) ťažisko: $x_0 = \frac{C+B}{2} = \frac{[0.5,1]+[2,0]}{2} = [1.25, 0.5]$

2) reflexia: $x_r = x_0 + \alpha(x_0 - A)$

$x_r = [1.25, 0.5] + 1([1.25, 0.5] - [0,0])$

$= [2.5, 1]$

$f(x_r) = 0.25$

$2.25 \leq 0.25 \leq 3$ ✗

3) expanzia: $x_e = x_0 + \beta(x_r - x_0)$

$x_e = [1.25, 0.5] + 2([2.5,1] - [1.25, 0.5])$

$= [3.75, 1.5]$

5/6

$f(x_e) = 3.9125$

$f(x_e) < f(x_r)$ ✗

$\Rightarrow A = x_r$

NELDER-MEAD - PRÍKLAD

Použite metódu **Nelder–Mead** na nájdenie minima funkcie

$$x^2 + y^2 + x - 2y - x * y + 2$$

počas prvých **troch iterácií**.

Nastavenia:

- počiatočný simplex je tvorený bodmi:

$$B_1 = \{1.2, 0.0\};\ B_2 = \{0.0, 0.8\};\ B_3 = \{0.0, 0.0\};$$

- koeficienty metódy:

$$\alpha = 1 \quad \text{(reflexia)}, \quad \gamma = 2 \quad \text{(expanzia)}, \quad \rho = 0.5 \quad \text{(kontrakcia)}$$

Nakreslite približne trojuholníky pre vypočítané tri iterácie.